CLARIAH - SIC 4.2

2022-01-13

Jan Wijffels: jan.wijffels@vub.be
DIGI - VUB - Brussels



Opzet




Scope SIC 4.2

Al-driven Participatory Digital Asset Enrichment

SIC 4.2 will provide a provide a set of scenarios, tool integration options, web and smartphone applications to allow researchers in digital humanities alongside volunteers to enrich their digital assets which either consists of images of text scans and raw transcribed texts with richer content through a combination of NLP technologies alongside human-in-the-loop interventions.

- Allow researchers/volunteers in digital humanities to enrich digital assets with content obtained through techniques such as NLP, HTR, OCR.
- ▶ Builds upon the CLARIAH-VL architecture, and further intends to connect to VSC Tier1/2 and DATA components.

How



- ▶ integrate with components of CLARIAH
 - use the crowd-sourcing toolkit Madoc as a backend platform
 - allow to connect to NLP models trained on SIC 5, use the Entity Referencing and the Linked Open Data toolkits (SIC 3.1 / SIC 3.2) on handwritten texts
 - allow to store data on the Vlaamse Supercomputer through iRODS and allows to build custom-made HTR and NER models on the Vlaamse Supercomputer
- ▶ integrate Madoc and SIC 5 models with the Inception human-in-the-loop annotation tool (https://inception-project.github.io)
- build smartphone applications allowing a researcher to collect feedback on straightforward tasks generated by AI toolkits
 - Named Entity Recognition / Text classification / Handwritten Text Recognition / Geospatial location identification
 - The app will allow validation, curation and improvement of model-generated output by researchers, volunteer civilians and students.

Vooruitgang



Vooruitgang

Toegang tot infrastructuur op VSC

- ► Sinds eind december 2021 VSC_2021_011 project goedgekeurd:
- ► Toegang tot Tier 1 sinds 12/01/2022 (duration of 2 years)
- VSC Tier-1
 - 1 publiek IP adres
 - 300 GB op shared filesystem op VSC Cloud
 - 1 CPUv1 VM and 1 GPUv1 VM,
 - 4 vCPUs + 1 vGPUs
 - ▶ 128 GB of RAM + persistent local disk space of 1 TB



Connectie naar Madoc

- Samen met Tom test project opgezet op Madoc om scans uit Brugse Vrije te laten transkriberen door vrijwilligers
- R pakket opgezet om data uit Madoc te halen
 - voor o.a. transcripties van vrijwilligers
 - https://github.com/DIGI-VUB/madoc.utils



Connectie naar Transkribus voor HTR

- R pakket opgezet om de Transkribus API op te roepen + verwerken Alto-XML / PageXML
- Functionaliteiten
 - Creatie van Transkribus projecten vanuit R
 - Uploaden van beelden naar Transkribus vanuit R
 - Layout analyse vanuit R met Transkribus tools
 - Alto-XML / PageXML downloaden + importeren in R
 - Transcripties uitvoeren vanuit R op Transkribus en Alto-XML / PageXML verwerken
 - https://github.com/DIGI-VUB/madoc.utils maar zal een eigen pakket worden



Ongoing

Handgeschreven Tekst Herkenning modellering

- PyLaia HTR model gebouwd op Getuigenissen data op VSC
- Verbeteren lijn segmentatie om CER lager te krijgen

Voor Getuigenissen

- ► IIIF image server https://sipi.io opzetten op VSC Tier 1 server
- Python module aan het opzetten om Named Entity Recognition modelbouw te vergemakkelijken op Inception
- Spatial location tool developped

Volgende stappen

- Alto-XML met transcripties opzetten met project op Madoc
- Inception migrereren van eigen server naar VSC + integreren met Madoc + voorbeeld
- ▶ BERT model bouwen op 18e/19e eeuws corpus
- Entity Recognition model op Brugse Vrije + vrijwilligers correctie
- Beginnen aan smartphone app

Contact:

- ▶ jan.wijffels@vub.be
- ► https://github.com/DIGI-VUB